

DOC 50 - Audio y Voz con IA para Publicidad

DOC 50 — Audio y Voz con IA para Publicidad

Categoría: Herramientas de Producción

Relacionado con: DOC 25 (Radio y Audio Publicitario como Formato Creativo)

Última actualización: Mayo 2026

Nivel: Avanzado — Director de Producción

Índice

1. El Audio con IA en la Producción Publicitaria Moderna
 2. ElevenLabs: Locución Publicitaria de Calidad
 3. Dirección de Locución con IA
 4. Suno AI: Música Original para Publicidad
 5. Udio AI: Alternativa a Suno
 6. Diseño de Sonido con IA
 7. Producción de Audio Completo con IA
 8. Audio para Video Publicitario
 9. Branded Audio y Sonic Branding con IA
 10. Legal y Ética en Audio con IA
 11. Calidad y Control de Producción
 12. Cómo usar este documento con IA
-

1. El Audio con IA en la Producción Publicitaria Moderna

Antes vs. después: cómo cambió la producción de audio con IA

Hasta 2022, la producción de audio publicitario tenía una cadena de valor fija y costosa. Un spot de radio de 30 segundos requería: un locutor profesional con estudio propio o renta de cabina, un productor musical o licencia de librería, un ingeniero de mezcla, y mínimo 48 horas de proceso entre brief y entrega. El costo mínimo real rondaba los 200 a 800 dólares por pieza, dependiendo del mercado y la calidad del talento. Para marcas medianas o campañas con múltiples versiones, este proceso era un cuello de botella creativo y financiero.

Con la llegada de ElevenLabs en 2023 y la maduración de Suno y Udio en 2024-2025, la cadena de producción colapsó hacia una sola estación de trabajo. Un productor de audio publicitario con IA puede hoy entregar: locución en 4 minutos, música original en 8 minutos,

mezcla básica en 20 minutos, y spot finalizado en menos de una hora. El costo marginal por pieza se redujo a centavos de dólar en escala.

Lo que no cambió: la necesidad de criterio editorial, dirección creativa, conocimiento de lo que funciona sonoramente, y el oído entrenado para distinguir lo que convierte de lo que simplemente "suena bien".

La IA democratizó el acceso a la producción. No democratizó el criterio.

El stack de audio IA para publicidad: herramientas y cuándo usar cada una

El stack estándar de un productor de audio publicitario con IA en 2025-2026 se organiza en tres capas:

Capa 1 — Voz y locución:

- ElevenLabs (estándar de industria para locución publicitaria)
- Adobe Podcast Enhanced Speech (corrección de audio de campo)
- Descript (edición de audio guiada por texto, útil para testimoniales)

Capa 2 — Música:

- Suno AI (jingles, música de fondo, piezas completas con letra)
- Udio AI (géneros específicos, mayor control tonal, piezas instrumentales complejas)
- Soundraw (música generada por IA con control de segmentación por sección)

Capa 3 — Efectos de sonido y mezcla:

- ElevenLabs Sound Effects (efectos de sonido generados por descripción de texto)
- Adobe Audition / Audacity (edición y mezcla final)
- Riverside.fm (grabación y exportación de alta calidad)
- Auphonic (masterización automática para broadcast y plataformas digitales)

Regla de decisión rápida:

Necesidad	Herramienta primaria	Alternativa
Locución con voz humana	ElevenLabs	Descript Overdub
Jingle con letra	Suno AI	Udio AI
Música de fondo instrumental	Udio AI	Suno (modo instrumental)
Sonic logo / stinger	Suno (5s)	Udio (clip corto)
Efectos de sonido	ElevenLabs SFX	Freesound + edición
Masterización	Auphonic	Adobe Audition (manual)

Cuándo el audio IA reemplaza la producción tradicional y cuándo no puede

El audio IA reemplaza la producción tradicional cuando:

- El proyecto tiene tiempos cortos y presupuesto limitado
- Se necesitan múltiples variantes de una misma pieza (A/B testing de locuciones)
- La campaña es digital-first y no requiere sindicación broadcast
- El cliente no tiene un patrimonio sonoro establecido que proteger
- El brief es genérico en términos de personalidad vocal

El audio IA no puede reemplazar cuando:

- La marca tiene una voz humana registrada como activo (voz corporativa que el público reconoce y relaciona con la marca)
 - Se requiere locución en idiomas con matices regionales muy específicos que ElevenLabs aún no captura con precisión (quechua, idiomas indígenas, dialectos muy cerrados)
 - El proyecto es broadcast nacional o internacional con exigencias de producción certificadas
 - La actuación vocal es el producto creativo central (audiolibros de narrador específico, personajes con actuación dramática)
 - Se requiere improvisación, entrevistas o contenido no guionado
-

2. ElevenLabs: Locución Publicitaria de Calidad

Por qué ElevenLabs es el estándar para locución con IA

ElevenLabs se diferencia de todas las alternativas por tres razones técnicas:

1. Modelo de síntesis de voz basado en contexto emocional. No simplemente convierte texto a fonemas. Analiza el contexto semántico del texto y modula la prosodia (ritmo, melodía, énfasis) en función de lo que el texto significa. Una frase como "Solo por hoy, 50% de descuento" recibe un patrón de entonación diferente a "El dolor crónico no debería definir tu vida", aunque ambas tengan estructura similar.

2. Biblioteca de voces con entrenamiento en audio de alta calidad. A diferencia de TTS (text-to-speech) convencionales entrenados con datos de internet de calidad heterogénea, las voces de ElevenLabs son entrenadas con grabaciones de actores de voz profesionales en condiciones de estudio.

3. Control granular de parámetros. Stability, similarity boost y style exaggeration permiten al productor ajustar el comportamiento de la voz como si estuviera mezclando en una

consola.

Tipos de voz disponibles: cómo seleccionar la voz correcta para cada marca

ElevenLabs organiza sus voces en categorías. Para publicidad, las más relevantes son:

Voces masculinas profesionales (narración): Adecuadas para marcas de autoridad, tecnología, finanzas, productos industriales. Características a buscar: articulación clara, registro barítono o tenor medio, pace moderado.

Voces femeninas cálidas (conexión emocional): Adecuadas para salud, bienestar, educación, retail, marcas de lifestyle. Características: calidez en el ataque de las vocales, resonancia media-alta, naturalidad en pausas.

Voces jóvenes de alta energía: Adecuadas para marcas de entretenimiento, gaming, comida rápida, moda. Características: pace rápido, variación tonal amplia, articulación informal.

Voces neutras de autoridad científica: Adecuadas para farmacéuticas, seguros, legal, tecnología médica. Características: pace deliberado, muy poca variación emocional, articulación precisa.

Proceso de selección de voz:

1. Definir el arquetipo humano de la marca (si la marca fuera una persona, ¿cómo hablaría? ¿Qué edad tendría? ¿Dónde creció?)
2. Mapear ese arquetipo a 3-5 voces candidatas en la biblioteca
3. Generar el mismo párrafo de prueba con cada voz (preferiblemente el cierre del spot, que es la parte más exigente emocionalmente)
4. Escuchar en auriculares y en parlante de teléfono (así se escucha el 70% del audio publicitario digital)
5. Seleccionar con el criterio: ¿esta voz haría que me detuviera al hacer scroll?

El problema de la locución IA que suena artificial: cómo evitarlo

Los patrones que delatan a una locución artificial son:

Entonación plana en listas. Cuando el texto tiene una enumeración ("resistente, impermeable y liviano"), la IA tiende a aplicar el mismo patrón tonal en cada elemento. Un locutor humano sube en los primeros, baja en el último. Solución: separar cada elemento con coma y punto y coma alternado para romper el patrón.

Énfasis en palabras incorrectas. La IA enfatiza palabras basándose en frecuencia estadística, no en intención comunicacional. "Esta oferta NO tiene precedentes" puede enfatizar "oferta" en lugar de "NO". Solución: usar mayúsculas estratégicas para forzar énfasis ("esta oferta NO tiene precedentes").

Respiraciones mecánicas. Las pausas largas a veces generan un sonido de respiración sintética que el oído detecta como artificial. Solución: editar manualmente las respiraciones en post o ajustar el parámetro de stability para reducir la variación entre respiraciones.

Pace uniforme. Un locutor humano acelera en la información secundaria y desacelera en la información clave. La IA tiende a mantener un pace más uniforme. Solución: usar elipsis (...) para forzar desaceleración en puntos clave.

Cierre sin descenso tonal. Los spots deben cerrar con un descenso tonal que señale finalización. La IA a veces mantiene el tono elevado hasta el final. Solución: terminar el guión con un punto y agregar un signo de exclamación solo si realmente quieres tono ascendente de cierre.

Técnicas para que suene natural: puntuación estratégica, pausas, énfasis

Sistema de puntuación para dirección de ElevenLabs:

Elemento tipográfico	Efecto en ElevenLabs
Coma (,)	Pausa corta (0.2-0.3s)
Punto y coma (;)	Pausa media (0.4-0.5s)
Punto (.)	Pausa larga (0.6-0.8s)
Elipsis (...)	Pausa muy larga + descenso tonal (1-1.5s)
Mayúsculas	Énfasis y volumen elevado
Guion (—)	Pausa con interrupción, cambio de ritmo
Paréntesis con instrucción	Indicación de emoción/tono

Ejemplos aplicados:

Versión sin dirección:

"Consigue tu préstamo en 24 horas sin papeleo y sin garantías. Llama ahora."

Versión con dirección para ElevenLabs:

"Consigue tu préstamo... en 24 horas. Sin papeleo. Sin garantías. (con convicción) Llama AHORA."

La segunda versión fuerza: pausa dramática antes de "24 horas", tres frases cortas con punch individual, instrucción emocional explícita, y énfasis en la palabra de acción.

Voice cloning: qué es, cuándo es útil, implicaciones éticas

El voice cloning de ElevenLabs permite entrenar un modelo de voz a partir de muestras de audio de una persona específica. Con 3 a 5 minutos de audio limpio, ElevenLabs puede generar una voz sintética que replica la voz original con alta fidelidad.

Casos de uso legítimos en publicidad:

- Una marca tiene un portavoz humano (ejecutivo, fundador, figura pública) que ha grabado voiceovers previamente. Con su consentimiento, se puede clonar su voz para generar variantes de spots sin repetir sesiones de grabación.
- Un actor de voz contratado para una campaña puede, bajo contrato específico, ceder derechos de clonación para producción de variantes en el mismo proyecto.
- Un creador de contenido puede clonar su propia voz para producción masiva de contenido.

Límites éticos no negociables:

- Nunca clonar la voz de una persona sin consentimiento explícito y escrito.
- Nunca usar voz clonada para hacer decir a alguien algo que no dijo.
- Nunca usar voz clonada de figuras públicas para endorsements falsos.
- Nunca usar voz clonada para engañar al receptor haciéndole creer que está escuchando a la persona real, si el contexto implica consecuencias (salud, finanzas, decisiones importantes).

El consentimiento informado debe especificar: qué textos se generarán, en qué plataformas se publicará, durante cuánto tiempo, y si la persona conserva el derecho a retirar el consentimiento.

Configuración de parámetros: stability, similarity, style exaggeration

Stability (Estabilidad): Controla qué tan consistente es la voz entre frases. Alta estabilidad (0.7-1.0) = voz muy uniforme, menos variación emocional, ideal para narración informativa. Baja estabilidad (0.2-0.5) = más variación natural, más expresividad, ideal para locución emocional. Para publicidad, el rango 0.4-0.6 es el más versátil.

Similarity Boost (Amplificación de similitud): Controla qué tan fielmente la salida se aproxima al modelo de voz entrenado. Alto similarity (0.8-1.0) = más parecida al modelo pero menos flexible. Bajo similarity (0.3-0.6) = más variación pero puede perder carácter de la voz. Para la mayoría de aplicaciones publicitarias: 0.7-0.85.

Style Exaggeration (Exageración de estilo): Amplifica los rasgos expresivos del modelo de voz. En 0 = expresión neutra. En 0.5-0.7 = expresividad aumentada, útil para spots de alta energía. En 1.0 = expresividad máxima, puede volverse caricaturesca. Para publicidad emocional: 0.3-0.5. Para publicidad de entretenimiento: 0.5-0.7.

Configuración por tipo de spot:

Tipo de spot	Stability	Similarity	Style
Institucional / corporativo	0.75	0.80	0.15

Tipo de spot	Stability	Similarity	Style
Promocional / oferta	0.50	0.75	0.45
Emocional / salud	0.45	0.80	0.35
Entretenimiento / gaming	0.35	0.70	0.65
Legal / farma (disclaimer)	0.85	0.85	0.05

Flujo de producción: guión → ElevenLabs → edición → entrega

Paso 1 — Guión marcado: Recibir o escribir el guión y aplicar el sistema de puntuación de dirección. Verificar que el guión tiene el tiempo correcto (a 150 palabras por minuto como referencia estándar, 30 segundos = 75 palabras, 60 segundos = 150 palabras).

Paso 2 — Selección de voz y configuración: Elegir la voz, configurar los parámetros según el tipo de spot, hacer una prueba con las primeras dos líneas antes de generar todo el guión.

Paso 3 — Generación por bloques: Para spots largos, generar por párrafos o bloques semánticos, no todo el guión junto. Esto permite regenerar solo las partes que no quedaron bien sin repetir todo el proceso.

Paso 4 — Revisión de calidad: Escuchar con auriculares en buena calidad. Identificar: palabras mal enfatizadas, pausas inadecuadas, artefactos de audio, respiraciones artificiales.

Paso 5 — Edición en DAW: Importar los bloques de audio a Audacity o Adobe Audition. Limpiar silencios, ajustar niveles, aplicar EQ básico si es necesario (cortar frecuencias debajo de 80Hz para limpiar rumble, realzar suavemente en 3-5kHz para presencia).

Paso 6 — Exportación: Exportar en WAV 48kHz 24-bit para producción o MP3 320kbps para entrega digital directa.

3. Dirección de Locución con IA

Cómo "dirigir" a ElevenLabs como si fuera un locutor humano

Dirigir a un locutor humano implica comunicar intención emocional, ritmo y enfoque. Dirigir a ElevenLabs implica traducir esas mismas intenciones al lenguaje que el sistema puede interpretar: puntuación, tipografía y anotaciones en el texto.

El productor que trata a ElevenLabs como "una máquina que convierte texto a audio" obtiene resultados mediocres. El productor que lo trata como "un locutor que necesita indicaciones precisas" obtiene resultados de calidad profesional.

La diferencia fundamental: un locutor humano interpreta la intención detrás del texto. ElevenLabs interpreta solo las señales explícitas en el texto. Por eso, todas las intenciones deben estar explicitadas.

El guión marcado para IA: indicaciones de ritmo, pausa, énfasis en el texto

El guión marcado es la versión del guión preparada específicamente para ser procesada por ElevenLabs. No es el guión de presentación al cliente, ni el guión de revisión creativa. Es un documento técnico de producción.

Formato recomendado del guión marcado:

[VIBE: cálido, cercano, como hablándole a un amigo]

[PACE: moderado, sin apuro]

¿Sabías que el 80% de los peruanos... no tienen un plan de ahorro?

(reflexivo) No es falta de dinero. Es falta de un sistema.

Nuestro banco NO te cobra por tener una cuenta de ahorros. NUNCA. Y tu dinero crece... automáticamente, cada mes.

(con convicción creciente) Porque el mejor momento para empezar... siempre fue hoy.

(cálido, directo) Banco Origen. Tu dinero, trabajando para ti.

Las anotaciones entre corchetes son contexto general que el locutor (humano o IA) debería tener en mente. Las instrucciones entre paréntesis antes de una frase son indicaciones de actuación.

Técnica del paréntesis de emoción: (emocionado), (solemne), (urgente)

ElevenLabs responde a instrucciones emocionales cuando están ubicadas inmediatamente antes de la frase que deben afectar. Las instrucciones más efectivas son:

- (con urgencia) — Acelera el pace, sube el tono
- (solemne) — Desacelera, baja el tono
- (cálido) — Suaviza el ataque de las vocales
- (emocionado) — Aumenta la variación tonal
- (confidencial) — Reduce el volumen, tono íntimo
- (con autoridad) — Pace firme, énfasis en consonantes
- (aliviado) — Tono descendente, pace suave
- (con convicción) — Ritmo firme, sin vacilaciones

- (dramático) — Pausa antes, tono descendente
- (directo) — Sin adornos, pace estable, articulación clara

Ejemplo aplicado:

Sin instrucción: "Este es el momento de actuar."

Con instrucción: "(con convicción, pace lento) Este... es el momento... de ACTUAR."

El segundo genera un entregable completamente diferente sin cambiar el copy.

Cómo obtener 10 variantes de la misma línea para elegir la mejor

Para una línea crítica (el cierre del spot, la propuesta de valor principal, la llamada a la acción), generar una sola versión es un error de proceso. El procedimiento correcto es:

1. Generar la línea con la configuración base (3 veces en la misma sesión, para capturar variaciones naturales del modelo)
2. Cambiar el parámetro de stability en 0.1 puntos hacia arriba y generar 2 versiones más
3. Cambiar stability en 0.1 puntos hacia abajo y generar 2 versiones más
4. Probar con estilo exaggeration +0.2 y generar 2 versiones
5. Probar con una instrucción de emoción diferente y generar la versión final

Resultado: 10 variantes de la misma línea con variaciones reales. Escuchar las 10 en secuencia en el contexto del spot completo (no de forma aislada) y seleccionar la que mejor fluye con el audio que la rodea.

A/B testing de locuciones: cómo seleccionar la que convierte más

En campañas digitales donde el audio es elemento crítico (spots de YouTube, audio ads en Spotify, locuciones en TikTok), el A/B testing de locuciones es una palanca de optimización frecuentemente ignorada.

Proceso de A/B testing de audio:

1. Producir el spot con dos variantes de locución: una más emocional, una más directa
2. Mantener constante todo lo demás: música, SFX, imágenes si aplica
3. Publicar ambas versiones con presupuesto dividido equitativamente
4. Medir no solo CTR sino tiempo de visualización (una locución más lenta puede tener menor CTR pero mayor retención)
5. En audio-only (Spotify, radio digital), medir completion rate como métrica principal

El dato histórico de la industria: la locución más emocional gana en awareness. La más directa gana en conversión directa. El tipo de campaña define cuál es el benchmark correcto.

4. Suno AI: Música Original para Publicidad

Qué es Suno y por qué cambió la producción musical para marcas

Suno AI es un generador de música que produce canciones completas (letra, instrumentación, producción) a partir de un prompt de texto. Lanzado en versión pública en 2024, en 2025 alcanzó una calidad que lo hizo viable para producción publicitaria real.

El impacto en publicidad fue específico: democratizó el acceso a música original. Antes de Suno, una marca pequeña o mediana tenía tres opciones: pagar por una licencia de librería musical (50 a 500 dólares por pista, con restricciones de uso), contratar a un productor musical (500 a 5,000 dólares por pieza original), o usar música que todos estaban usando. Suno eliminó ese límite de entrada.

Lo que Suno genera bien: jingles melódicos, música de fondo con estado de ánimo específico, stingers cortos, canciones con letra que integran el mensaje de la marca.

Lo que Suno no controla bien: estructuras musicales muy complejas, géneros ultra-específicos con características técnicas precisas, piezas que deben coincidir en tempo exacto con una edición de video ya finalizada (aunque esto se puede resolver en post con time-stretching).

Tipos de música que Suno genera: jingles, background music, stingers, sonic logos

Jingles: Canciones cortas (15 a 60 segundos) que integran el nombre o mensaje de la marca en la letra. Son el tipo de música publicitaria más memorioso. Suno puede generarlos con instrucciones específicas de letra.

Background music (música de fondo / music bed): Piezas instrumentales de 30 a 120 segundos que crean el ambiente emocional de un spot sin protagonismo. La locución va encima. Suno genera excellent music beds con instrucciones de mood e instrumentación.

Stingers: Fragmentos de 3 a 8 segundos que funcionan como separadores o cierres. Alta energía, impacto inmediato. Útiles para transiciones en spots de video o cierres de cuñas de radio.

Sonic logos: La firma musical de la marca, 2 a 5 segundos. Es la versión más corta y más memorable del universo sonoro de la marca. El "ta-ta-ta-TAAA" de Intel o el "ba da ba ba baa" de McDonald's son ejemplos icónicos. Suno puede generar candidatos para sonic logos con prompts muy específicos.

Anatomía del prompt de Suno: género + mood + instrumentos + tempo + letra

El prompt de Suno tiene estructura modular. Cada componente influye en el output de forma predecible:

Estructura base:

```
[género musical], [mood/emoción], [instrumentos principales], [tempo descriptivo], [características de producción], lyrics: "[letra si aplica]"
```

Ejemplo para spot de banco:

```
cinematic corporate pop, inspirational and trustworthy, acoustic guitar, soft piano, orchestral strings, moderate tempo, clean production, no drums in intro, lyrics: "Tu dinero tiene un hogar / donde crece sin parar / Banco Origen, hoy y siempre / tu futuro está aquí"
```

Ejemplo para spot de energéticos:

```
high energy electronic, aggressive and powerful, heavy synth bass, driving drums, distorted lead, fast tempo 140bpm, club-ready production, no lyrics, instrumental only
```

Modificadores de control importantes:

- no lyrics / instrumental only — elimina la voz generada
- [tempo]bpm — intenta anclar el tempo (no siempre exacto, verificar con metrónomo)
- [intro] — puede agregar indicaciones de sección para estructurar la pieza
- radio edit — señala que debe ser una pieza compacta y bien estructurada
- fade out ending — cierre con fade en lugar de final abrupto

Generación de jingles: cómo hacer que la canción lleve el mensaje

El jingle publicitario con IA requiere una capa de trabajo que va más allá de describir el género musical: requiere diseñar la letra antes del prompt.

Proceso de creación de jingle con Suno:

Paso 1 — Escribir la letra primero. La letra debe incluir: el nombre de la marca (al menos una vez), la propuesta de valor principal en forma memorable, y un cierre con la tagline si existe. La letra debe tener ritmo y rima que permita cantarse. Longitud recomendada: 4 a 8 líneas para un spot de 30s.

Paso 2 — Identificar el género adecuado. El género debe ser coherente con el posicionamiento de la marca. Una marca premium no debería tener un jingle en trap. Una

marca de tradición familiar no debería tener un jingle en EDM a menos que haya una razón estratégica muy clara.

Paso 3 — Construir el prompt completo incluyendo la letra como instrucción explícita. En Suno, la letra en el prompt tiene alta influencia sobre el output cuando está bien formateada.

Paso 4 — Generar 4 a 6 variantes. Suno tiene variación estocástica: dos generaciones con el mismo prompt pueden dar resultados muy diferentes. Generar varias opciones y seleccionar la que mejor casa con la marca.

Paso 5 — Extensión o edición. Si el jingle generado tiene 45 segundos pero el spot necesita 30s, editar en post para cortar o hacer loop de la sección mejor. Si necesita extensión, usar la función "Extend" de Suno para alargar la pieza de forma cohesiva.

Música de fondo (music bed): cómo generar el ambiente correcto para un spot

La música de fondo es posiblemente el uso más valioso de Suno en publicidad porque tiene menor exigencia de perfección (no tiene letra que analizar, no tiene voz que juzgar) y alto impacto en el tono emocional del spot.

Prompts de music bed por categoría de spot:

Para spot de salud/bienestar:

gentle acoustic, warm and hopeful, acoustic guitar fingerpicking, soft piano, light strings, slow tempo, no percussion, ambient, healing mood, instrumental only, radio-ready production

Para spot de tecnología/innovación:

modern minimal electronic, innovative and forward-thinking, synthesizers, light percussion, arpeggiated bass, medium tempo, clean mix, Apple-style product launch feel, instrumental only

Para spot de promoción/liquidación:

upbeat fun pop, energetic and playful, claps, acoustic guitar, bass, driving drums, fast tempo, summery, commercial pop feel, no lyrics

Para spot gastronómico:

warm acoustic jazz, inviting and sensorial, acoustic guitar, upright bass, light brushed drums, moderate swing tempo, relaxed, café atmosphere, instrumental only

Stingers y cierres musicales: el logo sonoro en 3-5 segundos

Los stingers son las piezas más difíciles de generar con Suno porque requieren alta densidad de impacto en muy poco tiempo, y Suno tiende a generar piezas de duración media (30s o más) por defecto.

Técnica para generar stingers:

- 1. Pedir a Suno una pieza de 15-20 segundos con las características del stinger
- 2. Seleccionar los 3-5 mejores segundos de la pieza generada (generalmente el pico de energía o el momento de resolución armónica)
- 3. Editar en DAW aplicando fade in de 0.2s y fade out de 0.3s

Prompt para stinger:

dramatic orchestral hit, triumphant, brass fanfare, short punchy ending, cinematic, powerful, 5 seconds, no intro buildup, immediate impact

Para sonic logos con melodía identificable:

brand sonic logo, 3-note memorable melody, warm and trustworthy, piano and soft strings, resolves clearly, professional, no percussion, 4 seconds

5. Udio AI: Alternativa a Suno

Diferencias entre Suno y Udio: cuándo usar cada uno

Udio AI compite directamente con Suno pero tiene características diferentes que lo hacen preferible en ciertos contextos publicitarios.

Suno vs. Udio — Comparativa de producción:

Dimensión	Suno	Udio
Velocidad de generación	Más rápido	Más lento
Control de tempo	Aproximado	Más preciso
Calidad de géneros pop/comercial	Excelente	Buena
Calidad de géneros orquestales	Buena	Excelente
Calidad de géneros jazz/acústico	Buena	Muy buena
Control de estructura musical	Limitado	Mayor control por secciones
Letra en idioma español	Aceptable	Comparable
Longitud de generación	Hasta 4 minutos	Hasta 3 minutos

Dimensión	Suno	Udio
Función de extensión	Sí	Sí

Regla práctica: Usar Suno como primera opción para jingles pop, música comercial energética y piezas con letra en español. Usar Udio cuando se necesita mayor profundidad orquestal, géneros de nicho con mayor precisión técnica, o mayor control sobre la estructura por secciones.

Fortalezas específicas de Udio: géneros, calidad, control

Udio destaca en:

Música orquestal y cinematográfica: Para spots institucionales, campañas de lanzamiento con alta producción, o cualquier pieza que requiera profundidad de cuerdas, metales y percusión orquestal, Udio tiende a producir resultados más sofisticados.

Géneros especializados: Jazz, bossa nova, world music, música latina con instrumentación específica (salsa, cumbia, bolero moderno) tienden a tener mayor autenticidad en Udio.

Control de secciones: Udio permite indicar en el prompt estructuras de sección (intro, verse, chorus, bridge, outro) con mayor precisión, lo que ayuda a producir piezas con arquitectura musical más predecible.

Técnicas de prompt para Udio

La estructura de prompt en Udio funciona de forma similar a Suno pero responde mejor a descriptores técnicos musicales:

```
[sección: intro 8 bars, verse 16 bars, chorus 8 bars, outro 4 bars]
genre: cinematic orchestral
mood: triumphant, epic, emotional
instruments: full orchestra, strings lead, brass accents, timpani, light piano
tempo: 76bpm, 4/4 time
production: film score quality, Hans Zimmer influenced
no vocals, instrumental only
```

La especificidad técnica (compases, tempo exacto, métrica) en Udio produce resultados más precisos que en Suno.

Integración en el flujo de producción de audio

La integración práctica de Udio en el flujo de producción es idéntica a Suno: generar, seleccionar, editar en DAW, mezclar con locución y SFX. La diferencia está en la etapa de

selección: Udio puede requerir más generaciones para encontrar el resultado óptimo, pero cuando acierta, la calidad puede superar a Suno en los géneros donde destaca.

Flujo combinado Suno + Udio:

Para proyectos exigentes, algunos productores usan ambas herramientas en paralelo: generan el mismo brief en ambas plataformas y seleccionan los mejores elementos de cada una. Esto es factible cuando el tiempo de producción lo permite y cuando hay presupuesto de suscripción para ambas plataformas.

6. Diseño de Sonido con IA

Sound effects con IA: herramientas

ElevenLabs Sound Effects: La función de efectos de sonido de ElevenLabs genera efectos a partir de descripciones de texto. A diferencia de las librerías de SFX donde se busca por categoría, aquí se describe exactamente el sonido necesario y el sistema lo genera.

Ejemplo de prompt para ElevenLabs SFX:

- "A glass door opening in a modern office, quiet ambient room tone"
- "Car engine starting and driving away on a wet street at night"
- "Coins dropping into a metal container, one by one, satisfying"
- "Notification sound, short, positive, digital, 1 second"

La ventaja es que el SFX generado es original y libre de derechos. La limitación es que los efectos muy específicos o de gran complejidad acústica (explosiones detalladas, entornos naturales complejos) aún tienen menor calidad que librerías profesionales como SoundSnap o BBC Sound Effects.

Adobe Podcast (Enhanced Speech): No genera SFX sino que mejora audio de campo. Útil para restaurar testimonios grabados en locaciones imperfectas o en cámara de teléfono.

Freesound + edición: Para SFX muy específicos, la combinación de Freesound.org (biblioteca de efectos Creative Commons) con edición manual en Audacity sigue siendo la opción más confiable cuando los resultados de IA no alcanzan el nivel requerido.

Foley publicitario: los sonidos que hacen que un producto se vea y escuche premium

El foley publicitario es el diseño de sonido específico para que los productos se perciban de mayor calidad. Algunos de los elementos de foley más importantes en publicidad:

El sonido de los alimentos: El sizzle (crepitación de carne en sartén), el crunch (crujido de chips, galletas, vegetales frescos), el pour (líquido siendo servido). Estos sonidos están hyper-producidos en publicidad: el sizzle de una hamburguesa en un comercial de McDonald's es más fuerte y satisfactorio de lo que sería en la realidad. Con IA, se pueden generar variantes de estos sonidos hasta encontrar la versión que maximice el antojo.

El sonido de los materiales: El snap de plástico premium vs. plástico barato, el ruido de una puerta de automóvil cerrando (un sonido diseñado meticulosamente por los fabricantes de autos), el sonido de una tela de alta calidad al moverse. Estos detalles en publicidad refuerzan la percepción de calidad del producto.

El sonido del ambiente: El entorno sonoro sitúa al espectador. Un spot de tarjeta de crédito premium puede ambientarse sonoramente en un restaurante de alta gama (vajilla fina, conversaciones bajas, música de piano) sin mostrar el restaurante, solo con el soundscape.

Ambient sound: construir el entorno sonoro de un spot

El ambient sound (o room tone) es la capa de sonido ambiental que da textura al audio de un spot. Sin ambient, el audio suena "muerto" o de estudio, lo que puede funcionar para ciertos formatos (informes corporativos, contenido educativo) pero crea una sensación de frialdad en spots emocionales.

Tipos de ambient sound por contexto publicitario:

- Hogar familiar: electrodomésticos suaves, pasos sobre madera, voces de fondo lejanas
- Ciudad moderna: tráfico suave, viento urbano, pasos en pavimento
- Naturaleza/aire libre: pájaros, viento suave, agua lejana
- Oficina: tecleo de computadora, aire acondicionado, puertas lejanas
- Retail/tienda: murmullo de personas, música de fondo, señales de caja registradora

Con ElevenLabs SFX, se puede generar ambient sound por descripción:

"Indoor coffee shop ambience, low murmur of conversations, espresso machine in background, jazz music faintly playing, warm and cozy"

Sound design para video: sincronización de efectos con imagen

En la post-producción de video publicitario con IA, la sincronización del audio con la imagen es el paso que más trabajo manual requiere porque los generadores de audio no "ven" el video.

Proceso de sincronización:

1. Editar el video primero hasta tener el corte final
2. Exportar el video sin audio (o con el audio de referencia en bajo volumen)

3. Identificar en el timeline los puntos de impacto que necesitan SFX (cortes de cámara, aparición de producto, texto animado, transiciones)
4. Generar los SFX necesarios por separado
5. Importar todos los elementos a un DAW con el video como referencia visual
6. Colocar cada SFX en el punto exacto del timeline
7. Ajustar niveles y añadir la música de fondo y la locución
8. Exportar la mezcla final

La herramienta más práctica para este proceso sin acceso a Adobe Audition es DaVinci Resolve (versión gratuita) que tiene un módulo Fairlight completo para edición de audio con video.

7. Producción de Audio Completo con IA

El flujo completo: guión → locución → música → SFX → mezcla

El flujo de producción completo de un spot de audio con IA tiene las siguientes etapas:

Etapas 1 — Pre-producción:

- Brief creativo (objetivo, audiencia, mensaje, tono)
- Redacción del guión
- Marcación del guión para dirección de ElevenLabs
- Brief de música para Suno/Udio
- Lista de SFX necesarios

Etapas 2 — Producción de elementos:

- Generación de locución en ElevenLabs (por bloques)
- Generación de música en Suno o Udio (múltiples variantes)
- Generación de SFX en ElevenLabs SFX o Freesound
- Selección de los mejores elementos de cada lote de generación

Etapas 3 — Post-producción:

- Importar todos los elementos al DAW
- Editar locución (limpiar silencios, corregir artefactos)
- Colocar música de fondo con niveles correctos (música 15-18dB debajo de locución)
- Agregar SFX en puntos de impacto
- Balancear la mezcla completa

Etapas 4 — Masterización y entrega:

- Aplicar masterización para el medio de destino
- Exportar en el formato y spec técnico requerido
- QA final: escuchar en auriculares, en teléfono, en parlante de escritorio

Herramientas de edición y mezcla: Audacity, Adobe Audition básico, Descript

Audacity (gratuito): Suficiente para edición básica, eliminación de silencios, EQ simple y exportación en múltiples formatos. Limitación: no tiene ventana de video para sincronización, el flujo de trabajo con múltiples pistas puede ser menos intuitivo que las alternativas.

Adobe Audition: Estándar de industria para post-producción de audio publicitario. La vista multitrack permite colocar todos los elementos (locución, música, SFX) en capas visuales claras. Tiene herramientas de restauración de audio (Noise Reduction, Spectral Repair) que son útiles para corregir artefactos de ElevenLabs. Costo: incluido en Adobe Creative Cloud.

Descript: Software de edición de audio (y video) guiada por texto. Transcribe el audio y permite editar el audio editando el texto transcrito. Muy útil para editar entrevistas, testimoniales y contenido no guionado. Para spots de IA, tiene menor utilidad porque el audio ya viene perfectamente limpio.

Masterización para diferentes plataformas: Instagram, TikTok, Spotify, broadcast

Cada plataforma tiene un nivel de loudness objetivo diferente. Publicar sin masterizar para la plataforma correcta resulta en audio que suena demasiado suave (se normaliza hacia abajo) o que distorsiona.

Niveles de referencia por plataforma:

Plataforma	Loudness objetivo	Formato recomendado
Spotify	-14 LUFS	MP3 320kbps o FLAC
YouTube	-14 LUFS	AAC 256kbps
Instagram / TikTok	-14 LUFS (stories), -16 LUFS (feed)	AAC 256kbps
Radio broadcast (Latinoamérica)	-23 LUFS	WAV 48kHz 16-bit
Podcast	-16 LUFS	MP3 192kbps

LUFS (Loudness Units relative to Full Scale) es la medida de loudness integrado que usan las plataformas digitales. Audacity puede medir LUFS con el plugin "EBU R128 Loudness

Normalization". Adobe Audition incluye el medidor de LUFS de forma nativa.

Auphonic (servicio en línea, tiene tier gratuito con horas limitadas) automatiza la masterización para diferentes destinos: se sube el audio y se selecciona el perfil (Podcast, YouTube, Broadcast) y entrega el archivo masterizado.

Specs técnicos de audio por plataforma: bitrate, sample rate, loudness

Para producción (archivos de trabajo):

- Sample rate: 48kHz (estándar de video y broadcast)
- Bit depth: 24-bit (mayor rango dinámico para edición)
- Formato: WAV no comprimido

Para entrega digital:

- Sample rate: 44.1kHz o 48kHz según requerimiento del cliente
- Bit depth: 16-bit para entrega final (equivalente a calidad de CD)
- Formato: WAV o MP3 320kbps

Para redes sociales:

- MP3 192kbps mínimo, 320kbps recomendado
- Mono o stereo según la plataforma (TikTok procesa bien stereo; Instagram Feed es preferible stereo)

8. Audio para Video Publicitario

Cómo el audio define el 50% del impacto emocional de un video

Existe evidencia de estudios de experiencia de usuario que cuando se desactiva el audio de un video y se mantiene la imagen, los espectadores reportan una experiencia emocional significativamente reducida. El audio no solo complementa el video: genera la emoción que la imagen libera pero no crea por sí sola.

El ejemplo más claro: la misma escena de un automóvil en una carretera cambia completamente según el audio. Con música orquestal épica: el auto es un símbolo de libertad. Con música de jazz suave: el auto es sofisticación. Con música electrónica agresiva: el auto es adrenalina. La imagen es idéntica en los tres casos.

Para publicidad, esto significa que el director de audio es co-director creativo del spot, aunque raramente se le reconoce ese rol.

Sincronización audio-video: técnicas de montaje sonoro

El montaje sonoro en publicidad tiene dos técnicas principales:

Sincronización on-beat: Los cortes de video coinciden con los golpes de la música (el kick drum, el downbeat de cada compás, el inicio de un coro). Crea energía, ritmo, sensación de producción alta. Usado en spots de moda, tecnología, entretenimiento.

Sincronización emocional: El audio dirige la emoción independientemente del ritmo musical. Un violín que sube de tono coincide con el primer plano de una madre y su hijo, no necesariamente con el beat. Usado en spots de seguros, bancos, salud, causas sociales.

Para sincronizar audio generado por IA con video, el flujo más práctico es:

1. Cortar el video con marcadores en los puntos de impacto emocional
2. Generar la música con un tempo que permita alinear esos puntos con downbeats o fases musicales naturales
3. Usar time-stretching (en Audacity o Audition) si el tempo de la música generada no coincide exactamente, siempre que la variación sea menor al 5-8% del tempo original (variaciones mayores producen artefactos de audio)

El mix perfecto: locución + música + SFX (niveles de referencia)

La mezcla de un spot de audio para video sigue una jerarquía fija:

Nivel 1 — Locución: El elemento más importante. Debe ser perfectamente inteligible en cualquier condición de escucha. Nivel de referencia: -12 a -6 dBFS en los picos más altos. La voz debe ser el elemento más presente.

Nivel 2 — SFX de impacto: Efectos de sonido que acompañan momentos clave del video. Deben ser audibles pero no competir con la locución. Nivel de referencia: -18 a -12 dBFS.

Nivel 3 — Música de fondo: Debe ser perceptible pero no competir con la locución. La regla práctica: cuando la locución está presente, la música debe bajar al nivel donde se percibe como soporte, no como protagonista. Nivel de referencia con locución activa: -24 a -18 dBFS. Sin locución: -16 a -12 dBFS.

SFX ambient: El más suave de todos. -28 a -22 dBFS. Solo debe percibirse en parlantes de calidad o auriculares, no en teléfonos con volumen medio.

Post-sincronización: reemplazar audio de rodaje con audio IA

En producción de video con presupuesto reducido, frecuentemente el audio capturado en locación es de baja calidad (ruido ambiente, viento, eco). En lugar de regrabar en estudio, la post-sincronización con IA permite reemplazar ese audio:

1. Transcribir el diálogo del rodaje (Adobe Podcast o Whisper AI)
2. Limpiar la transcripción y marcarla para ElevenLabs

3. Generar el audio de reemplazo con la voz más cercana al actor original (o con una voz diferente si la audiencia no conoce al actor)
4. Sincronizar el nuevo audio con el video haciendo coincidir los movimientos de labios en los planos cerrados

Esta técnica tiene limitaciones obvias en planos muy cerrados de boca y en frases cortas donde la sincronía labial es muy visible. Funciona mejor en planos medios y generales, y en contenido donde la cara del hablante no está visible.

9. Branded Audio y Sonic Branding con IA

Crear el sonic logo de una marca con Suno: proceso completo

El sonic logo es la firma sonora de la marca: 2 a 5 segundos de audio que aparece al final de cada pieza de comunicación y que, con el tiempo, el público asocia automáticamente con la marca. Es el equivalente sonoro del logotipo visual.

Proceso completo de creación del sonic logo con IA:

Fase 1 — Estrategia de sonido: Definir los atributos que el sonic logo debe comunicar. Ejemplo para una marca de seguros: "seguridad, calidez, experiencia, confianza". Traducir esos atributos a parámetros musicales: instrumentación cálida (cuerdas, piano), resolución armónica clara (no terminar en disonancia), tempo lento, tres notas descendentes que transmitan estabilidad.

Fase 2 — Brief de generación: Construir el prompt para Suno con alta especificidad.

Ejemplo de prompt para sonic logo:

```
brand sonic logo, 3 descending notes on piano, warm orchestral strings  
resolution, trustworthy and calm, 4 seconds, no drums, major key, clear  
melodic resolution, professional jingle ending
```

Fase 3 — Generación masiva: Generar 20 a 30 variantes. Los sonic logos tienen un estándar de calidad muy alto porque se repetirán miles de veces. La variante correcta debe ser: memorizable en la primera escucha, capaz de evocar los atributos de la marca, y musicalmente resuelta (no dejar al oyente con sensación de inconclusión).

Fase 4 — Selección y refinamiento: Elegir las 3 mejores variantes. Testear con personas que no conocen el proyecto (preferiblemente miembros del target de la marca). Preguntar: "¿Qué te transmite este sonido?" y verificar si las respuestas coinciden con los atributos definidos en la Fase 1.

Fase 5 — Producción final: La variante seleccionada puede necesitar refinamiento: editar la duración exacta, ajustar el nivel de fade out, eliminar artefactos. Exportar en WAV de alta

calidad como master del sonic logo.

Fase 6 — Integración en el sistema: Crear variantes del sonic logo: versión completa (4-5s), versión corta (2s), versión de solo notas (sin reverb, para producción), versión con fade. Documentar en el brandbook sonoro.

Brand voice consistente con ElevenLabs: la voz como activo de marca

La voz de una marca es tan importante como su color o su tipografía. Una vez seleccionada la voz en ElevenLabs, debe documentarse como activo de marca con los parámetros exactos para garantizar consistencia en todas las producciones.

Documentación de brand voice:

```
Marca: [Nombre]
Plataforma: ElevenLabs
Voice ID: [ID único de la voz seleccionada]
Stability: 0.52
Similarity Boost: 0.78
Style Exaggeration: 0.25
Notas de dirección estándar: tono cálido y cercano, pace moderado, énfasis
en la última palabra del cierre
Ejemplos de guión marcado de referencia: [link a archivo]
```

Este documento debe estar en el manual de producción del cliente y ser entregado a cualquier productor que trabaje con la marca en el futuro.

Variaciones aceptables de brand voice:

La voz de marca puede tener variantes contextuales sin perder coherencia:

- Versión formal (stability +0.1, style -0.1) para comunicados institucionales
- Versión emocional (stability -0.1, style +0.15) para campañas de causa social o momentos de conexión humana
- Versión urgente (para promociones con tiempo limitado): pace más rápido, style +0.2

Todas las variantes deben documentarse y aprobarse por el cliente antes de producir.

Soundscape de marca: el universo sonoro completo

El soundscape de marca es el conjunto completo de elementos sonoros que conforman el universo auditivo de una marca. Va más allá del sonic logo e incluye:

- El sonic logo (firma)
- El brand music bed (música de fondo estándar para los spots)
- La brand voice (la voz oficial de la marca)

- Los brand SFX (efectos de sonido asociados a los productos o a momentos clave de la comunicación)
- El brand ambient (el entorno sonoro típico de los spots de la marca)

Cuando todos estos elementos están definidos y son consistentes, crean una experiencia auditiva reconocible independientemente de si el receptor está viendo un video, escuchando la radio, o en un punto de venta.

Con IA, construir un soundscape completo de marca es un proyecto de 1 a 3 días de trabajo, a diferencia de los 2 a 6 meses que podría tomar con producción tradicional de estudio.

Casos de branded audio: Intel, Netflix, McDonald's (análisis de sus elementos sonoros)

Intel Inside (el sonic logo más reconocido del mundo):

El "bong" de Intel es una melodía de 5 notas en do mayor, generada originalmente en 1994 por Walter Werzowa. Tres características hacen que funcione: es simple (5 notas, fácil de retener), es neutral emocionalmente (no es alegre ni triste, solo "tecnológico"), y es consistente (prácticamente no ha cambiado en 30 años). Lección: un sonic logo no debe intentar expresar mucho. Debe expresar una sola cosa con claridad.

Netflix (el "ta-dum"):

El sonido de apertura de Netflix, diseñado en 2015 por Lon Bender y editado con el sonido de un bajo eléctrico manipulado, dura exactamente 3 segundos. Tiene un impacto dramático inmediato por su volumen y su frecuencia baja. Crea anticipación antes de que empiece cualquier contenido. Lección: los sonic logos con frecuencias bajas (bass, subbass) tienen mayor impacto físico y son más difíciles de ignorar.

McDonald's ("ba da ba ba baa"):

El jingle de cinco notas de McDonald's ("I'm Lovin' It") es técnicamente un sonic logo con letra. La versión solo con la melodía es igualmente reconocible sin palabras. Es cantable, está en un rango cómodo para cualquier voz humana, y tiene una resolución ascendente final que transmite positividad. Lección: un sonic logo cantable tiene mayor capacidad de propagación orgánica porque las personas lo reproducen inconscientemente.

10. Legal y Ética en Audio con IA

Voice cloning sin consentimiento: el límite legal y ético

El voice cloning sin consentimiento es ilegal en múltiples jurisdicciones y constituye una violación grave de los derechos de imagen y de la personalidad de las personas afectadas.

En Estados Unidos, el NO FAKES Act (propuesto y en proceso legislativo en 2024-2025) establecería protecciones federales contra el uso no autorizado de voces de personas reales. Varios estados (California, Tennessee) ya tienen legislación específica.

En Latinoamérica, aunque la legislación específica sobre voz sintética es aún incipiente, las leyes de protección de datos personales (LGPD en Brasil, Ley de Protección de Datos en México, Ley Habeas Data en Colombia) incluyen la voz como dato biométrico protegido. Usar la voz de una persona sin consentimiento puede constituir una violación de estas leyes con consecuencias civiles y en algunos casos penales.

Regla operativa: Nunca usar voice cloning de una persona real sin un contrato firmado que especifique: alcance de uso, plataformas, duración, compensación y derecho a retiro de consentimiento. Este contrato debe ser revisado por un abogado, no es un documento que se improvisa.

Derechos de la música generada por IA: quién es el autor

La situación legal de los derechos de autor en música generada por IA es compleja y aún está siendo definida por los tribunales y las legislaciones de diferentes países.

Estado actual (2025-2026):

- En Estados Unidos, la Oficina de Derechos de Autor (Copyright Office) ha establecido que las obras generadas íntegramente por IA sin intervención humana creativa significativa no son elegibles para protección de derechos de autor bajo la ley actual.
- Suno y Udio ofrecen en sus planes de pago derechos comerciales sobre las piezas generadas para uso comercial, pero estos "derechos" son licencias contractuales del servicio, no derechos de autor en el sentido legal pleno.
- La protección real existe cuando el humano tiene una contribución creativa significativa (edición, arreglos, letras escritas por el humano) que se integra con el output de IA.

Implicación práctica para publicidad: Documentar la contribución humana en el proceso de producción de música con IA. Conservar los prompts, las decisiones de selección y edición, y cualquier modificación realizada al output de IA. Esto construye un registro de la autoría humana en el proceso creativo.

Uso de voces sintéticas en publicidad: regulaciones emergentes

La Unión Europea, a través del AI Act (en vigor desde 2024), establece que los sistemas de IA de "alto riesgo" en ciertos sectores deben etiquetarse como generados por IA. Para publicidad, esto se traduce en la obligación en algunos países europeos de indicar cuando el contenido fue generado con IA, incluyendo las voces.

En Latinoamérica, las regulaciones son actualmente menos estrictas, pero las tendencias globales indican que en los próximos 2-3 años habrá mayor presión regulatoria para la transparencia en el uso de IA en publicidad.

Recomendación proactiva: Incluso donde no es legalmente obligatorio, considerar incluir disclosure de IA en material publicitario cuando:

- La audiencia puede razonablemente esperar que haya un humano real detrás de la voz
- La marca tiene un compromiso declarado con la transparencia
- El contenido toca temas sensibles (salud, finanzas, bienestar emocional)

Disclosure de IA en audio publicitario: cuándo es necesario

El disclosure (la declaración de que el contenido fue generado con IA) puede ser:

Obligatorio: Cuando la regulación local lo exige (verificar en cada mercado), cuando se usa la voz clonada de una persona pública que puede ser reconocida por la audiencia, cuando el contenido implica afirmaciones de salud o financieras donde la identidad del hablante es relevante para la credibilidad.

Recomendable pero no obligatorio: Cuando la audiencia es técnicamente sofisticada y puede detectar el origen IA del audio, cuando la marca quiere posicionarse como innovadora y el uso de IA es un diferenciador positivo, cuando existe riesgo reputacional si la audiencia descubre el origen IA sin haber sido informada.

No necesario: En la mayoría de los casos de música de fondo generada por IA (las librerías de música de stock tampoco declaran quién las compuso), en efectos de sonido genéricos, en locuciones donde la voz es claramente sintética y no pretende ser una persona real identificable.

11. Calidad y Control de Producción

Checklist de calidad de audio antes de publicar

Nivel técnico:

- ☐ Loudness integrado dentro del rango de la plataforma de destino (LUFS correcto)
- ☐ Sin distorsión (ningún pico por encima de -1 dBFS True Peak)
- ☐ Sample rate y bit depth correctos para el destino
- ☐ Formato de archivo correcto (WAV, MP3, AAC según especificación)
- ☐ Duración exacta según el formato de pauta (15s, 30s, 60s, etc.)

Nivel creativo:

- ☐ La locución es completamente inteligible en todas las condiciones de escucha
- ☐ El mensaje principal se comprende sin necesidad de ver la imagen (si es spot de video)
- ☐ El cierre con el nombre de la marca y la llamada a la acción es claro
- ☐ La música no compite con la locución en ningún momento

- ☐ El tono emocional del audio es coherente con el objetivo de la campaña

Nivel de producción:

- ☐ No hay artefactos de audio audibles (clicks, pops, glitches de ElevenLabs)
- ☐ No hay respiraciones artificiales o mecánicas
- ☐ Las transiciones entre bloques de locución son suaves
- ☐ Los SFX están sincrónicos con los momentos visuales correspondientes
- ☐ El fade in y fade out de la música son suaves y no abruptos

Prueba en múltiples dispositivos:

- ☐ Escuchado en auriculares de calidad
- ☐ Escuchado en parlante de computadora (simulación de escritorio)
- ☐ Escuchado en altavoz de teléfono (simulación de escucha móvil)
- ☐ Escuchado a volumen bajo (¿sigue siendo inteligible la locución?)

Errores frecuentes en audio IA: respiraciones artificiales, clicks, artefactos

Respiraciones artificiales: ElevenLabs a veces inserta sonidos de respiración sintéticos entre frases. Se detectan como un suave "hhhh" antes de una nueva oración. Son más frecuentes cuando la voz tiene stability baja y style exaggeration alta. Corrección: en Audacity o Audition, seleccionar el segmento de respiración artificial y aplicar silencio, o reducir el volumen de ese segmento en 20-30 dB.

Clicks y pops: Artefactos de procesamiento que aparecen como ruidos cortos e impulsivos. Frecuentes en las uniones entre bloques de audio cuando se concatenan múltiples generaciones de ElevenLabs. Corrección: en Adobe Audition, usar la herramienta "Click/Pop Eliminator" en la sección de restauración de audio. En Audacity, usar el plugin "Click Removal".

Glitches de modulación: Cambios abruptos de tono o volumen en mitad de una frase. Más frecuentes en textos con puntuación inusual o en frases muy largas. Corrección: regenerar ese segmento específico con el texto ligeramente modificado (cambiar puntuación, dividir la frase, reformular).

Sibilancias excesivas: Los sonidos "s" y "sh" a veces se exageran en las voces de ElevenLabs. Corrección: en el EQ de Audition o Audacity, usar un filtro de De-essing (reducción de frecuencias en el rango 5-8kHz donde viven las sibilancias).

Inconsistencia entre bloques: Cuando se genera el guión en múltiples bloques, el timbre de la voz puede variar ligeramente entre bloques. Se nota como un cambio sutil de carácter vocal entre frases. Prevención: usar exactamente los mismos parámetros de configuración en todas las generaciones de la misma sesión. Corrección: igualar el EQ de los diferentes bloques para acercar el timbre.

Corrección de audio en post: lo que el oído humano detecta y la IA no se autocorriga

Los sistemas de IA de generación de audio no tienen retroalimentación auditiva propia. Generan audio y lo entregan sin escucharlo. El oído humano entrenado detecta irregularidades que ningún sistema de post-procesamiento automático puede identificar sin contexto:

La duda de intención: Una pausa de 0.4 segundos antes de "garantizado" puede sonar como duda del locutor sobre el claim. La IA no sabe si esa pausa es dramática o nerviosa. El oído humano sí.

El tono condescendiente: Ciertas combinaciones de velocidad y tono en frases explicativas pueden sonar patronizantes. La IA no lo detecta. El oyente humano sí, aunque no siempre pueda articular por qué.

La falta de autenticidad emocional: Un locutor humano siente (o actúa) lo que dice. La IA aproxima la emoción estadísticamente. Hay un 10-15% de los casos donde el resultado suena "correcto técnicamente pero no auténtico". Solo el oído humano detecta esa diferencia.

Por estas razones, el oído humano como filtro final es un paso irrenunciable en el control de calidad de audio publicitario con IA. La revisión final debe hacerla alguien con criterio editorial, no solo con habilidades técnicas.

12. Cómo usar este documento con IA

Esta sección contiene los prompts, templates y frameworks para usar Claude (u otro LLM) junto con las herramientas descritas en este documento, de forma que el proceso de producción sea reproducible y eficiente.

Prompt para generar el guión marcado para dirección de ElevenLabs

Usar este prompt con Claude cuando se tiene el guión final del spot y se necesita convertirlo en guión de dirección para ElevenLabs:

```
Eres un director de locución experto en producción publicitaria con ElevenLabs.
```

```
Tengo el siguiente guión para un spot de [duración: 30/60 segundos] para la marca [nombre de la marca], cuyo tono es [descripción del tono: cálido/energético/institucional/urgente].
```

El gui3n es:
[PEGAR GUI3N AQUÍ]

Por favor, convierte este gui3n en un gui3n marcado para direcci3n de ElevenLabs usando las siguientes convenciones:

- Coma (,) para pausa corta
- Punto y coma (;) para pausa media
- Punto (.) para pausa estandar
- Elipsis (...) para pausa dramática y descenso tonal
- MAYÚSCULAS para palabras con énfasis especial
- (instrucci3n emocional) antes de las frases que requieren actuaci3n específica
- Guion largo (–) para cambios de ritmo abruptos

Incluye al inicio del gui3n marcado:
[VIBE: descripci3n del estado emocional general]
[PACE: descripci3n del ritmo general]

Justifica brevemente las decisiones de direcci3n más importantes.

Prompt para crear el brief de música para Suno o Udio

Usar este prompt con Claude para generar el brief de música antes de trabajar en Suno o Udio:

Eres un director musical especialista en producci3n publicitaria.

Necesito crear la música para un spot publicitario con las siguientes características:

Marca: [nombre]
Producto/servicio: [descripci3n]
Objetivo del spot: [awareness / conversi3n / branding / lanzamiento]
Duraci3n: [15/30/60 segundos]
Tono emocional: [descripci3n]
Público objetivo: [descripci3n]
Referencia de estilo musical si existe: [o "sin referencia específica"]
La música llevará: [locuci3n encima / es instrumental pura / lleva letra de jingle]

Con esta informaci3n, genera:

1. Un prompt para Suno AI para crear la música de fondo
2. Un prompt alternativo para Udio AI
3. Una descripci3n de la estructura musical recomendada (intro / desarrollo / cierre)

4. Los parámetros a evitar en la música (elementos que se contradicen con el tono de la marca)
5. 3 géneros musicales alternativos a explorar si el primero no funciona

Formato de salida: estructurado, directo, sin texto de relleno.

Prompt para diseñar el sonic branding de una marca

Usar este prompt con Claude para desarrollar la estrategia de sonic branding antes de la producción:

Eres un estratega de sonic branding con experiencia en marcas latinoamericanas.

Necesito desarrollar el universo sonoro completo para la siguiente marca:

Nombre de la marca: [nombre]

Rubro: [categoría de industria]

Posicionamiento: [descripción en 1-2 frases]

Valores de marca: [lista de 3-5 valores]

Audiencia: [descripción del target]

Tono de comunicación existente (visual y verbal): [descripción]

Marcas de referencia (no necesariamente del mismo rubro) cuyos universos sonoros admiran: [lista]

Genera un documento de estrategia de sonic branding que incluya:

1. Personalidad sonora de la marca (4-6 atributos auditivos)
2. Paleta de géneros musicales permitidos y prohibidos
3. Descripción de la brand voice ideal (con parámetros para selección en ElevenLabs)
4. Brief del sonic logo: qué debe transmitir, qué instrumentos, cuántas notas, duración
5. Prompt de Suno para generar el sonic logo
6. Prompt de ElevenLabs para encontrar la brand voice ideal
7. Guía de uso: cuándo usar cada elemento del soundscape

Formato: documento estructurado, en español latinoamericano, sin emojis.

Template de producción de audio completo para un spot de 30s

Este template es el documento de producción que debe completarse para cada spot antes de iniciar la producción. Sirve como brief técnico y creativo unificado.

Brief de Producción de Audio
Spot: [Nombre del spot]
Fecha: [Fecha de producción]
Cliente: [Nombre del cliente]

1. DATOS BÁSICOS

- Duración: 30 segundos
- Formato: ☐ Solo audio ☐ Audio para video ☐ Ambos
- Plataformas de destino: ☐ Instagram ☐ TikTok ☐ YouTube ☐ Radio digital ☐ Otro: ___
- Spec técnico requerido: [LUFS objetivo / formato / sample rate]

2. GUIÓN ORIGINAL

[Pegar el guión sin marcar]

Conteo de palabras: ___ palabras (objetivo: 60-75 palabras para 30s a 150wpm)

3. GUIÓN MARCADO PARA ELEVENLABS

[Pegar el guión con todas las marcas de dirección]

4. CONFIGURACIÓN DE ELEVENLABS

- Voice ID: ___
- *Voice name*: ___
- Stability: ___
- *Similarity Boost*: ___
- Style Exaggeration: ___
- *Notas adicionales*: ___

5. BRIEF MUSICAL

- Tipo: ☐ Music bed ☐ Jingle con letra ☐ Stinger ☐ Sonic logo
- Herramienta: ☐ Suno ☐ Udio
- Prompt de Suno/Udio:
[Pegar el prompt]
- Duración musical requerida: ___ segundos
- Estructura: [intro / desarrollo / cierre]

6. SFX REQUERIDOS

Momento del spot	Descripción del SFX	Herramienta	Estado
--- --- --- ---			
[00:00-00:02]	[descripción]	ElevenLabs SFX / Freesound	Pendiente
[00:xx-00:xx]	[descripción]		

7. MEZCLA – NIVELES DE REFERENCIA

- Locución: -12 a -6 dBFS
- Música de fondo: -24 a -18 dBFS (con locución activa)
- SFX de impacto: -18 a -12 dBFS

- Ambient: -28 dBFS

8. CHECKLIST DE ENTREGA

- [] Locución revisada y aprobada
- [] Música seleccionada y aprobada
- [] SFX sincronizados
- [] Mezcla balanceada
- [] LUFS verificado para plataforma de destino
- [] Escuchado en auriculares, parlante de computadora y teléfono
- [] Archivo exportado en formato correcto
- [] Aprobación del cliente

9. ARCHIVOS DE ENTREGA

- Archivo master: [ruta o link]
- Locución aislada: [ruta o link]
- Música aislada: [ruta o link]
- Versión para edición (wav 48kHz 24bit): [ruta o link]
- Versión para publicación (formato final): [ruta o link]

Cierre

Este documento es un manual de referencia vivo. Las herramientas de audio IA evolucionan a un ritmo que puede hacer obsoletos algunos parámetros técnicos específicos en 6 a 12 meses. Lo que no cambia es el principio central: el criterio humano sobre qué funciona sonoramente en publicidad, y la habilidad de traducir ese criterio al lenguaje que las herramientas de IA pueden interpretar.

El productor que domine ese lenguaje de traducción entre intención creativa y prompt técnico tiene una ventaja competitiva que las herramientas por sí solas no pueden proporcionar.

Ver también: DOC 25 — Radio y Audio Publicitario como Formato Creativo | DOC 30 — Producción de Video con IA | DOC 40 — Herramientas de IA para Imágenes Publicitarias